

知识点归纳 · 概率论与数理统计

21305337 *Betelgeuse*

仅供学习参考，勿作商业用途


目录

1 概率论的基本概念	1
1.1 样本空间	1
1.2 常用公式	1
1.3 等可能概型（古典概型）	1
1.4 实际推断原理	1
1.5 条件概率（乘法公式）	1
1.6 全概率公式	2
1.7 独立性	2
2 随机变量	2
2.1 离散型随机变量	2
2.1.1 二项分布	3
2.1.2 泊松分布	3
2.2 连续型随机变量	3
2.2.1 均匀分布	3
2.2.2 指数分布	4
2.2.3 正态分布	4
2.3 [方法] 求一元函数的分布函数或密度函数	4
3 多维随机变量及其分布	4
3.1 联合分布	4
3.2 边缘分布	5
3.3 二维正态分布（要背）	5
3.4 条件分布	5
3.4.1 随机变量的独立性	6
3.4.2 条件分布律（离散情形）	6
3.4.3 条件概率密度（连续情形）	6
3.5 二元随机变量的一些函数的分布	6
3.5.1 离散型	6
3.5.2 连续型	7

4 随机变量的数字特征	8
4.1 数学期望的定义及一些性质	8
4.1.1 一元函数期望的计算公式	8
4.1.2 二元函数期望的计算公式	8
4.2 方差	9
4.2.1 切比雪夫不等式	9
4.3 协方差及相关系数	10
4.3.1 协方差	10
4.3.2 相关系数	10
4.4 矩、协方差矩阵	10
4.4.1 协方差矩阵	11
5 大数定律及中心极限定理	12
5.1 弱大数定律 (辛钦大数定律)	12
5.1.1 伯努利大数定律	12
5.2 中心极限定理 (独立同分布)	12
6 样本及抽样分布	13
6.1 常用的统计量	13
6.2 分位数	14
6.3 χ^2 分布	14
6.4 F 分布	14
6.5 t 分布	14
6.6 正态总体的抽样分布 (小样本分布)	15
6.6.1 单正态总体的抽样分布	15
6.6.2 双正态总体的抽样分布	15
6.7 一般总体的抽样分布的极限分布 *	15
7 参数估计	16
7.1 点估计	16
7.1.1 矩估计法 (ME 法)	16
7.1.2 最大似然估计法 (MLE 法)	17
7.2 估计量的评选标准	18
7.2.1 无偏性	18
7.2.2 有效性	18
7.2.3 相合性	18

1 概率论的基本概念

1.1 样本空间



1.2 常用公式

交换律: $A \cup B = B \cup A$; $A \cap B = B \cap A$

结合律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$

$A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$

对偶律: $\overline{A \cup B} = \overline{A} \cap \overline{B}$; $\overline{A \cap B} = \overline{A} \cup \overline{B}$

其他: $P(\overline{A}) = P(A) - P(AB)$

$P(A \cup B) = P(A) + P(B) - P(AB)$ (加法公式)

1.3 等可能概型 (古典概型)

条件: 1. 有穷性; 2. 等可能性

其中有放回抽样和不放回抽样

1.4 实际推断原理

概率很小的事件在一次试验中实际上几乎是不发生的

1.5 条件概率 (乘法公式)

$$P(B|A) = \frac{P(AB)}{P(A)}$$

1.6 全概率公式

划分

设 S 为试验 E 的样本空间, B_1, B_2, \dots, B_n 为 E 的一组事件。若 $B_i \cap B_j = \emptyset, i, j = 1, 2, \dots, n$; 且 $\bigcap_{k=1}^n B_k = S$ 则 B_1, B_2, \dots, B_n 为 S 的一个划分。

若 B_1, B_2, \dots, B_n 为 S 的一个划分, 则

$$P(A) = \sum_{k=1}^n P(A|B_k)P(B_k)$$

贝叶斯 (Bayes) 公式

若 B_1, B_2, \dots, B_n 为 S 的一个划分, 则 $P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{k=1}^n P(A|B_k)P(B_k)}, i = 1, 2, \dots, n$.

1.7 独立性

二元情形 def: 若 $P(AB) = P(A)P(B)$, 则 A, B 互相独立 (独立)

- 若 A, B 独立, $P(A) > 0$, 则 $P(B|A) = P(B)$.
- 若 A, B 独立, 则 A 与 \bar{B} , \bar{A} 与 B , \bar{A} 与 \bar{B} 也独立.

两两独立 $n > 2$ 时, 对于事件 A_1, A_2, \dots, A_n , 若 $\forall i \neq j$ 有 $P(A_i A_j) = P(A_i)P(A_j)$, 则称 A_1, A_2, \dots, A_n 两两独立.

互相独立 $n > 2$ 时, 对于事件 A_1, A_2, \dots, A_n , 若任意 $2, 3, \dots, n$ 个事件的积事件的概率都等于各事件概率之积, 则称 A_1, A_2, \dots, A_n 互相独立

2 随机变量

2.1 离散型随机变量

离散型随机变量 X 的分布律 表示 X 的所有可能取值及其概率的通式或表格

伯努利试验 试验 E 只有 A 及 \bar{A} 两种结果

n 重伯努利试验 将 E 独立重复进行 n 次

2.1.1 二项分布

设随机变量 X 为 n 次试验 E 中 A 发生的次数, 则 $P(X = k) = \binom{n}{k} p^k q^{n-k}$, 并记 $X \sim B(n, p)$.

2.1.2 泊松分布

若离散型随机变量 X 的分布律为

$$P\{X = k\} = \frac{\lambda^k}{e^\lambda k!}, \quad (\lambda > 0)$$

则称 X 服从参数为 λ 的**泊松分布**, 记为 $X \sim \pi(\lambda)$ 或 $Po(\lambda)$.

泊松定理 对常数 $\lambda, \forall n \in \mathbf{Z}$, 且有 $np_n = \lambda$, 则对 $\forall k \in \mathbf{Z}$ 有

$$\lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{e^\lambda k!}.$$

当 n 很大, p 很小 ($np = \lambda$), 有

$$\binom{n}{k} p^k (1 - p)^{n-k} \approx \frac{\lambda^k}{e^\lambda k!}.$$

2.2 连续型随机变量

分布函数 $F(x) = P\{X \leq x\}$, 性质: 1. 单调非降 2. 右连续性 3. 左极限存在 4. 规范性.

概率密度 $f(x)$, 其中 $F(x) = \int_{-\infty}^x f(t) dt, f(x) = \frac{\partial}{\partial x} F(x)$.

小结论 X 为连续型随机变量 $\Leftrightarrow F(x)$ 无间断点.

2.2.1 均匀分布

若 X 在 (a, b) 上服从均匀分布, 记为 $X \sim U(a, b)$, 密度函数为

$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{其他.} \end{cases}$$

2.2.2 指数分布

若 X 服从参数为 $\theta (\theta > 0)$ 的指数分布, 密度函数为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x > 0, \\ 0, & \text{其他.} \end{cases}$$

无记忆性 $P\{X > s+t | X > s\} = P\{X > t\}$.

2.2.3 正态分布

X 服从参数为 μ, θ 的正态分布, 记为 $X \sim N(\mu, \sigma^2)$, 概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty.$$

标准正态分布 $X \sim N(0, 1)$, $\begin{cases} \text{概率密度 } \varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \\ \text{分布函数 } \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt. \end{cases}$

2.3 [方法] 求一元函数的分布函数或密度函数

分布函数方法 若已知 $F_X(x)$, 且 $Y = g(X)$, 则

$$F_Y(y) = P\{Y \leq y\} = P\{g(X) \leq y\}$$

密度函数方法 (次选) 若已知 $F_X(x)$, 有 $Y = g(X), h = g^{-1}$, 即 $X = h(Y)$ (可数多段), 则

$$f_Y(y) = \sum f_X(x) \cdot |h'(y)| = \sum f_X[h(y)] \cdot |h'(y)|.$$

3 多维随机变量及其分布

n 维随机变量 $X(\omega) = (X_1(\omega), \dots, X_n(\omega))$, 其中 X_1, \dots, X_n 是定义在 S 上的随机变量.

3.1 联合分布

联合分布函数 $F(x, y) = P\{(X \leq x) \cap (Y \leq y)\}$, 记为 $P\{X \leq x, Y \leq y\}$.

- 关于 x 与 y 均单调非降, 右连续.
- 对 $\forall x_1 < x_2, y_1 < y_2, F(x_2, y_2) + F(x_1, y_1) \geq F(x_1, y_2) + F(x_2, y_1)$.

联合概率密度 $f(x, y), F(x, y) = \int_{-\infty}^y \int_{-\infty}^x f(x, y) dx dy, \left(f(x, y) = \frac{\partial^2}{\partial x \partial y} F(x, y) \right)$, 则 (X, Y) 为二维连续型随机变量, $f(x, y)(x, y)$ 的概率密度 (X 和 Y 的联合概率密度)

3.2 边缘分布

边缘分布律 (离散) (X, Y) 关于 X 的边缘分布律 $p_{i\bullet} = \sum_j p_{ij} = P\{X = x_i\}$.

边缘概率密度 (连续) (X, Y) 关于 X 的边缘概率密度为

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy = \frac{\partial F(x, +\infty)}{\partial x}.$$

3.3 二维正态分布 (要背)

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \times \exp \left\{ \frac{-1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_1}{\sigma_1} \right)^2 + \left(\frac{y-\mu_2}{\sigma_2} \right)^2 - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} \right] \right\}$$

其中 $\sigma_1, \sigma_2 > 0, -1 \leq \rho \leq 1$, 称 (X, Y) 服从参数为 $\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho$ 的二维正态分布, 记为 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$.

- $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho) \Rightarrow \begin{cases} X \sim (\mu_1, \sigma_1) \\ Y \sim (\mu_2, \sigma_2) \end{cases}$
- n 维正态随机变量的每个分量都是正态随机变量; **相互独立的** n 个正态随机变量组成 n 维正态随机变量.
- $\rho = 0 \Rightarrow f(x, y) = f_X(x) \cdot f_Y(y)$.
- 若 (X_1, \dots, X_n) 服从 n 维正态分布, 则 X_1, \dots, X_n **相互独立**等价于**两两不相关**.
- n 维正态分布的线性组合仍服从正态分布 (包括一维和多维).(P114)

三项分布 * $P\{(X, Y) = (i, j)\} = C_n^i C_{n-1}^j p^i q^j r^{n-i-j} = \frac{n!}{i!j!(n-i-j)!} p^i q^j r^{n-i-j}$, 其中 $p+q+r=1, i, j, n \in Z^+$, 则称 (X, Y) 服从三项分布.

3.4 条件分布

$Y \leq y$ 条件下 X 的条件分布函数:

$$F(x|Y \leq y) = P(X \leq x|Y \leq y) = \frac{P(X \leq x, Y \leq y)}{P(Y \leq y)} = \frac{F(x, y)}{F_Y(y)}$$

• $Y = y$ 条件下 X 的条件分布函数:

$$\begin{aligned} F_{X|Y}(x|y) &= P(X \leq x|Y = y) \\ &= \begin{cases} \frac{P(X \leq x, Y = y)}{P(Y = y)} \\ \lim_{\Delta y \rightarrow 0} \frac{P(X \leq x, y - \Delta y < Y \leq y)}{P(y - \Delta y < Y \leq y)} = \frac{\int_{-\infty}^x f(u, y) du}{f_Y(y)} = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du \end{cases} \end{aligned}$$

3.4.1 随机变量的独立性

若 $\forall x, y$, 均有

$$\begin{aligned} P(X \in I, Y \in J) &= P(X \in I) \cdot P(Y \in J), \forall I, J \\ \iff F(x, y) &= F_X(x) \cdot F_Y(y) \\ \iff f(x, y) &= f_X(x) \cdot f_Y(y) \text{ 在除去“面积”为 0 的集合成立} \\ \implies F_X(x) &= F(x|Y \leq y), F_Y(y) = F(y|X \leq x) \text{ (代替条件概率)} \end{aligned}$$

则称随机变量 X, Y 相互独立.

- A 与 B 互相独立 $\Leftrightarrow A$ 与 \bar{B} 互相独立 $\Leftrightarrow \bar{A}$ 与 B 互相独立 $\Leftrightarrow \bar{A}$ 与 \bar{B} 互相独立
- 随机变量 X_1, X_2, \dots, X_n 互相独立, 对 $\forall g_1(t), g_2(t), \dots, g_n(t)$, 随机变量 $g_1(X_1), g_2(X_2), \dots, g_n(X_n)$ 互相独立

3.4.2 条件分布律 (离散情形)

在 $Y = y_j$ 条件下随机变量 X 的条件分布律为:

$$P\{X = x_i|Y = y_j\} = \frac{P\{X = x_i, Y = y_j\}}{P\{Y = y_j\}} = \frac{p_{ij}}{p_{\bullet j}}$$

3.4.3 条件概率密度 (连续情形)

$Y = y$ 条件下 X 的条件概率密度为:

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{\text{概率密度}}{\text{边缘概率密度}}$$

3.5 二元随机变量的一些函数的分布

3.5.1 离散型

二项分布 若 $X \sim B(n, p), Y \sim B(m, p)$, X, Y 互相独立, 则 $X + Y \sim B(n + m, p)$.

泊松分布 若 $X \sim Po(\lambda_1), Y \sim Po(\lambda_2)$, X, Y 互相独立, 则 $X + Y \sim Po(\lambda_1 + \lambda_2)$.

3.5.2 连续型

(一) $Z = X + Y$ 的分布

卷积公式

设 (X, Y) 具有概率密度 $f(x, y)$, 且 X, Y 独立, 则 $Z = X + Y$ 的概率密度为:

$$F_{X+Y}(z) = \begin{cases} \int_{-\infty}^{+\infty} f(z-y, y)dy = \int_{-\infty}^{+\infty} f_X(z-y)f_Y(y)dy \\ \int_{-\infty}^{+\infty} f(x, z-x)dx = \int_{-\infty}^{+\infty} f_X(x)f_Y(z-x)dy \end{cases} \equiv f_X * f_Y$$

正态分布 若 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$, X, Y 互相独立, 那么 $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

(二) $Z = \frac{Y}{X}, Z = XY$ 的分布

设 (X, Y) 具有概率密度 $f(x, y)$, 且 X, Y 独立, 则 $Z = \frac{Y}{X}, Z = XY$ 的概率密度分别为:

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} |x|f(x, xz)dx = \int_{-\infty}^{+\infty} |x|f_X(x)f_Y(xz)dx$$

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|}f(x, \frac{z}{x})dx = \int_{-\infty}^{+\infty} \frac{1}{|x|}f_X(x)f_Y(\frac{z}{x})dx$$

(三) $\max\{X, Y\}$ 和 $\min\{X, Y\}$ 的分布

设 $U \equiv \max\{X_1, \dots, X_n\}$, 则有

$$F_U(u) = P\{X_1, \dots, X_n \leq u\} \xrightarrow{X_1, \dots, X_n \text{ 相互独立}} \prod_{i=1}^n F_{X_i}(x_i).$$

设 $V \equiv \min\{X_1, \dots, X_n\}$, 则有

$$F_V(v) = P\{X_1, \dots, X_n \leq v\} = 1 - P\{X_1, \dots, X_n > v\} \xrightarrow{X_1, \dots, X_n \text{ 相互独立}} 1 - \prod_{i=1}^n [1 - F_{X_i}(x_i)].$$

(四) $g_1(x, y)$ 和 $g_2(x, y)$ 的联合分布

$$\begin{aligned} F(g_1, g_2) &= P(g_1 \leq z_1, g_2 \leq z_2) = \iint_{\substack{g_1(x, y) \leq z_1 \\ g_2(x, y) \leq z_2}} f(x, y)dx dy \xrightarrow{\substack{\text{设 } x=\varphi(g_1, g_2) \\ y=\psi(g_1, g_2)}} \iint_{\substack{g_1 \leq z_1 \\ g_2 \leq z_2}} f(\varphi, \psi) \cdot |J|dg_1 dg_2 \\ &= \iint_{\substack{g_1 \leq z_1 \\ g_2 \leq z_2}} f(\varphi, \psi) \cdot \frac{D(\varphi, \psi)}{D(g_1, g_2)} dg_1 dg_2 \end{aligned}$$

4 随机变量的数字特征

4.1 数学期望的定义及一些性质

定义 (离散情形) 若级数 $\sum_k^{+\infty} x_k P(X = x_k)$ **绝对收敛** 则数学期望存在, (注意: 条件收敛不保证期望存在!) 则记

$$E(X) = \sum_k x_k P(X = x_k) = \sum_k x_k p_k$$

并称 $E(X)$ 为 X 的**数学期望**, 简称**期望**, 又称**均值**.

定义 (连续情形) 若 $\left| \int_{-\infty}^{+\infty} x |f(x)| dx \right| < +\infty$ (**绝对收敛**), 则记

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx \quad \left(= \int_0^1 x dF(x) \right) < +\infty$$

并称 $E(X)$ 为 X 的**期望**.

4.1.1 一元函数期望的计算公式

$g(x)$ 是实函数,

1) 若 X 为离散型,

$$E(g(X)) = \sum_k g(x_k) P\{X = x_k\}$$

2) 若 X 为连续型, 密度函数为 $f(x)$,

$$E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx.$$

以上两式都可写为

$$E(g(X)) = \int_0^1 g(x) dF(x) \quad (\text{勒贝格积分})$$

4.1.2 二元函数期望的计算公式

线性函数的期望

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

X, Y 独立的情形 (线性性) 若 X, Y 互相独立, 则

$$E(XY) = E(X)E(Y)$$

一般二元函数的期望 $g(x, y)$ 是实函数,

1) 若 (X, Y) 为离散型,

$$E(g(X, Y)) = \sum_{i,j} g(x_i, y_j) P\{X = x_i, Y = y_j\}$$

2) 若 (X, Y) 为连续型, 密度函数为 $f(x, y)$,

$$E(g(X, Y)) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy.$$

以上两式都可写为

$$E(g(X, Y)) = \iint g(x, y) dF(x, y) \quad (\text{勒贝格积分})$$

4.2 方差

$$D(X) \equiv E\{[X - E(X)]^2\} = E(X^2) - [E(X)]^2.$$

- $D(X) = 0 \iff P\{X = E(X)\} = 1.$
- $D(aX + c) = a^2 D(X).$
- 如果 X, Y 独立, 则 $D(X \pm Y) = D(X) + D(Y).$

4.2.1 切比雪夫不等式

设随机变量 X 具有数学期望 $E(X)$, 方差 $D(X)$, 则对 $\forall \varepsilon > 0$,

$$P\{|X - E(X)| \geq \varepsilon\} \leq \frac{D(X)}{\varepsilon^2}.$$

4.3 协方差及相关系数

4.3.1 协方差

$$\text{cov}(X, Y) = \sigma_{XY} \equiv E\{[X - E(X)][Y - E(Y)]\}$$

上式称为 X 和 Y 的协方差, 即 X 和 Y 的二阶混合中心矩.

- X 和 Y 成线性关系 ($Y = aX + b, a \neq 0$) $\iff \text{cov}(X, Y) = \sqrt{D(X)D(Y)}$
- X 和 Y 不相关 $\iff \text{cov}(X, Y) = 0$
- 若 X 和 Y 独立, 则 $\text{cov}(X, Y) = 0$ (反之不成立)
- $D(X \pm Y) = D(X) + D(Y) \pm 2\text{cov}(X, Y)$
- $\text{cov}(X, aY + bZ + c) = a\text{cov}(X, Y) + b\text{cov}(X, Z)$
- $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$
- $D(\sum_{i=1}^n a_i X_i + b) = \sum_{i=1}^n a_i^2 D(X_i) + \sum_{i < j} 2a_i a_j \text{cov}(X_i, X_j)$

4.3.2 相关系数

若 $D(X) \neq 0, D(Y) \neq 0$, 则 X, Y 的相关系数为

$$\rho_{XY} \equiv \frac{\text{cov}(X, Y)}{\sqrt{D(X)D(Y)}}$$

上式称为 X 和 Y 的协方差, 即 X 和 Y 的二阶混合中心矩.

- $|\rho_{XY}| \leq 1$
- $Y = aX + b(a > 0) \iff \rho_{XY} = 1$
- $Y = aX + b(a < 0) \iff \rho_{XY} = -1$
- X 和 Y 不相关 $\iff \rho_{XY} = 0$
- 若 X 和 Y 独立, 则 $\rho_{XY} = 0$ (反之不成立)
- X, Y 为二元正态分布或都是二值随机变量, 则不相关性与独立性等价.

4.4 矩、协方差矩阵

X 的 K 阶原点矩 (K 阶矩) 若 $E(X^k)$ 存在, 则称为 X 的 K 阶原点矩 (K 阶矩) .

X 的 K 阶中心矩 若 $E\{[X - E(X)]^k\}$ 存在, 则称为 X 的 K 阶中心矩.

X 和 Y 的 $k+l$ 阶混合矩 若 $E(X^k Y^l)$ 存在, 则称为 X 和 Y 的 $k+l$ 阶混合矩.

X 和 Y 的 $k+l$ 阶混合中心矩 若 $E\{[X - E(X)]^k [Y - E(Y)]^l\}$ 存在, 则称为 X 和 Y 的 $k+l$ 阶混合中心矩.

4.4.1 协方差矩阵

(X_1, X_2, \dots, X_n) 中分量的两两的协方差都存在, 则协方差矩阵为

$$\mathbf{C} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{bmatrix}$$

n 维正态分布 n 维正态随机变量 (X_1, X_2, \dots, X_n) 的概率密度定义为

$$f(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}} \sqrt{|\mathbf{C}|}} \exp\left[-\frac{1}{2}(\mathbf{X} - \boldsymbol{\mu})^T \mathbf{C}^{-1}(\mathbf{X} - \boldsymbol{\mu})\right],$$

$$\text{其中 } \mathbf{X} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix}.$$

5 大数定律及中心极限定理

5.1 弱大数定律 (辛钦大数定律)

依概率收敛

若 X_1, X_2, \dots 是一个无穷的随机变量列, 若 $\forall \varepsilon > 0$ 都有

$$\lim_{n \rightarrow \infty} P\{|X_n - X| < \varepsilon\} = 1,$$

则称序列 X_1, X_2, \dots 依概率收敛于随机变量 X (退化情况为常数 a),

记为 $X_n \xrightarrow{P} X$.

若 X_1, X_2, \dots, X_n 相互独立且服从同一分布, 且有 $E(X_k) = \mu$, 则

$$\bar{X} \xrightarrow{P} \mu.$$

n 充分大时, 频率接近概率.

依分布收敛 *

若 X_1, X_2, \dots 是一个无穷的随机变量列, 分布函数为 $F_1(x), F_2(x), \dots$, 如果对 X 的分布函数 $F(x)$ 的任意连续点 x , 都有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

则称随机变量列 X_1, X_2, \dots 依分布收敛于 X , 记为 $X_n \xrightarrow{L} X$.

5.1.1 伯努利大数定律

若 $f_A \sim B(n, p)$, 则 $\frac{f_A}{n} \xrightarrow{L} p$.

5.2 中心极限定理 (独立同分布)

若 X_1, X_2, \dots 相互独立且服从同一分布, 且有 $E(X_k) = \mu, \sqrt{D(X_k)} = \sigma$, 设 $S_n = X_1 + \dots + X_n$, 则

$$\frac{S_n - n\mu}{\sqrt{n}\sigma} \xrightarrow{L} X, \text{ 其中 } X \sim N(0, 1).$$

Tips

大数定律 定性

切比雪夫不等式 定量

中心极限定理 较精确的定量

6 样本及抽样分布

基本概念 总体 \supseteq 样本 \supseteq 个体
总体的容量 $>$ 样本容量

样本的性质 独立性、代表性.

样本值 样本 (X_1, \dots, X_n) 的值 (x_1, \dots, x_n) .

样本分布 $F(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i)$.

样本密度函数 $f(x_1, \dots, x_n) = \prod_{i=1}^n f(x_i)$.

样本的概率分布 $p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i)$.

统计量 (statistic) 样本 (X_1, \dots, X_n) 的函数 $g(X_1, \dots, X_n)$, 函数 g 必须是确定的, 不含未知参数, g 的取值可以是一维、多维的.

6.1 常用的统计量

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$.

样本标准差 $S = \sqrt{S^2}$.

未修正样本方差 $S_0^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$.

k 阶样本原点矩 $a_k = \frac{1}{n} \sum_{i=1}^n X_i^k$.

修正样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

k 阶样本中心矩 $m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$.


顺序统计量 随机变量 X_1, \dots, X_n 互相独立且同分布, 分布函数为 $F(x)$, 将其从小到大排序: $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$, 则 $X_{(k)}$ 的分布函数为 $F_k(x) = \sum_{i=1}^n C_n^i F^i(x) [1 - F(x)]^{n-i}$.

样本极小、极大值 $X_{(1)}, X_{(n)}$

样本极差 $X_{(n)} - X_{(1)}$

6.2 分位数

上侧 α 分位数 若 $\alpha \in (0, 1)$, $x_\alpha \in \mathbb{R}$ 满足 $P\{X > x_\alpha\} = \alpha$, 则称 x_α 为 X 的上侧 α 分位数.



通常, 对于上 α 分位数,

标准正态分布的记作 z_α ,

$\chi^2(n)$ 分布的记作 $\chi_\alpha^2(n)$,

$t(n)$ 分布的记作 $t_\alpha(n)$,

$F(n_1, n_2)$ 分布的记作 $F_\alpha(n_1, n_2)$.

双侧 α 分位数 设 X 是对称分布 (密度函数是偶函数) 的连续性随机变量, 若 $\alpha \in (0, 1)$, $T_\alpha \in \mathbb{R}$ 满足 $P\{|X| > T_\alpha\} = \alpha$, 则称 T_α 为 X 的双侧 α 分位数.

6.3 χ^2 分布

$X = X_1^2 + \cdots + X_n^2$, $X_1^2 + \cdots + X_n^2 \sim N(0, 1)$ 且相互独立, 则称 X 服从自由度为 n 的 χ^2 分布, 记为 $X \sim \chi^2(n)$.

- $E(X) = n, D(X) = 2n$.
- **可加性** 若 $X \sim \chi^2(m), Y \sim \chi^2(n)$, 则 $X + Y \sim \chi^2(m + n)$.
- $n = 1, 2$ 时单调递减; $n \geq 3$ 时先增后减, 极大值点为 $x = n - 2$.
- $\chi^2(2) = e\left(\frac{1}{2}\right)$. (指数分布)
- n 充分大时, (如 $n > 40$), $\chi_\alpha^2(n) \approx \frac{1}{2} \left(z_\alpha + \sqrt{2n - 1} \right)$.

6.4 F 分布

$X = \frac{U/m}{V/n}$, $U \sim \chi^2(m)$, $V \sim \chi^2(n)$ X, Y 相互独立, 则称 X 服从第一自由度为 m , 第二自由度为 n 的 F 分布, 记为 $X \sim F(m, n)$.

- 若 $X \sim F(m, n)$, 则 $\frac{1}{X} \sim F(n, m)$; $F_{1-\alpha}(m, n) = \frac{1}{F_\alpha(n, m)}$

6.5 t 分布

$X = \frac{U}{\sqrt{V/n}}$, $U \sim N(0, 1)$, $V \sim \chi^2(n)$, X, Y 相互独立, 则称 X 服从自由度为 n 的 t 分布, 记为 $X \sim t(n)$.

- 当 n 充分大 (如 $n > 50$), $t(n)$ 近似于 $N(0, 1)$.
- $E(X) = 0, D(X) = \frac{n}{n - 2}$

6.6 正态总体的抽样分布 (小样本分布)

6.6.1 单正态总体的抽样分布

若 $X \sim N(\mu, \sigma^2)$, X_1, \dots, X_n 为样本, \bar{X} 和 S^2 分别为样本均值和样本方差 (修正后), 有

$$\left\{ \begin{array}{l} U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \\ \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \\ (\mu \text{ 已知时用于推断 } \sigma^2) \\ \bar{X}(\text{或 } U) \text{ 与 } S^2 \text{ 相互独立} \end{array} \right. \Rightarrow T = \frac{U}{S/\sqrt{n}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1). \\ (\sigma^2 \text{ 已知时用于推断 } \mu)$$

6.6.2 双正态总体的抽样分布

若 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$, X_1, \dots, X_{n_1} 与 Y_1, \dots, Y_{n_2} 为样本, \bar{X}, \bar{Y} 和 S_1^2, S_2^2 分别为样本均值和样本方差 (修正后), 有

$$\left\{ \begin{array}{l} U = \frac{(\bar{X} - \bar{Y}) - (\mu_1, \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1) \\ F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1) \\ (\mu_1 - \mu_2 \text{ 已知时用于推断 } \frac{\sigma_1^2}{\sigma_2^2}) \\ U \text{ 与 } F \text{ 相互独立} \\ \text{设加权平均 } S^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2} \end{array} \right. \Rightarrow \begin{array}{l} \text{当 } \sigma_1 = \sigma_2 = \sigma, \\ T = \frac{U}{S} \sigma = \frac{(\bar{X} - \bar{Y}) - (\mu_1, \mu_2)}{S \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \\ \sim t(n_1 + n_2 - 2). \\ (\frac{\sigma_1^2}{\sigma_2^2} \text{ 已知时用于推断 } \mu_1 - \mu_2) \end{array}$$

6.7 一般总体的抽样分布的极限分布 *

若 X_1, \dots, X_n 为总体 X 的样本, \bar{X} 和 S^2 分别为样本均值和样本方差 (修正后), 设 $E(X) = \mu, D(X) = \sigma^2$, 有

$$\begin{array}{l} U_n = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{L} N(0, 1) \quad (\sigma^2 \text{ 已知时用于推断 } \mu) \\ T_n = \frac{\bar{X} - \mu}{S/\sqrt{n}} \xrightarrow{L} N(0, 1) \quad (\sigma^2 \text{ 未知时用于推断 } \mu) \end{array}$$

7 参数估计

7.1 点估计

估计 $\hat{\theta}(X_1, \dots, X_n)$ 为参数 θ 的估计量, $\hat{\theta}(x_1, \dots, x_n)$ 为参数 θ 的估计值, 二者统称为估计.

7.1.1 矩估计法 (ME 法)

设总体 X 的分布依赖于参数 $\theta = (\theta_1, \dots, \theta_m)$, X_1, \dots, X_n 是样本, 估计参数 θ 的过程如下:

Step1 由于各阶矩是参数的函数, 故可以列出方程组:

$$\begin{cases} \alpha_1 = E(X) = g_1(\theta_1, \dots, \theta_m), \\ \alpha_2 = E(X^2) = g_2(\theta_1, \dots, \theta_m), \\ \vdots \\ \alpha_m = E(X^m) = g_m(\theta_1, \dots, \theta_m). \end{cases} \quad \text{一般情况下可解得} \quad \begin{cases} \theta_1 = h_1(\alpha_1, \dots, \alpha_m) \\ \theta_2 = h_2(\alpha_1, \dots, \alpha_m) \\ \vdots \\ \theta_m = h_m(\alpha_1, \dots, \alpha_m). \end{cases}$$

注: 有时会出现某一个方程 (通常是期望的方程) 是恒等方程, 则需要把 $m+1$ 阶矩的方程也列出, 才能解出方程. (有效方程个数 = 未知参数个数)

Step2 计算

$$\begin{cases} A_1 = \frac{1}{n} \sum_{i=1}^n X_i \\ \vdots \\ A_m = \frac{1}{n} \sum_{i=1}^n X_i^m \end{cases} \quad \text{或} \quad \begin{cases} a_1 = \frac{1}{n} \sum_{i=1}^n x_i \\ \vdots \\ a_m = \frac{1}{n} \sum_{i=1}^n x_i^m \end{cases}$$

再用 A_1, \dots, A_m 或 a_1, \dots, a_m 代替上式中的 $\alpha_1, \dots, \alpha_m$, 得到矩估计量或矩估计值

$$\begin{cases} \hat{\theta}_1 = h_1(A_1, \dots, A_m) \\ \vdots \\ \hat{\theta}_m = h_m(A_1, \dots, A_m). \end{cases} \quad \text{或} \quad \begin{cases} \hat{\theta}_1 = h_1(a_1, \dots, a_m) \\ \vdots \\ \hat{\theta}_m = h_m(a_1, \dots, a_m). \end{cases}$$

7.1.2 最大似然估计法 (MLE 法)

Step 1

1° **离散型** 若总体 X 属离散型, 其分布律 $P\{X = x\} = p(x; \theta_1, \dots, \theta_m), \theta_i \in \Theta_i$ 的形式已知 (如 $B(n, p)$, 未知参数 $\theta_1 = n, \theta_2 = p$), 则事件 $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ 发生的概率为

$$L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_m) = \prod_{i=1}^n p(x_i; \theta_1, \dots, \theta_m).$$

2° **连续型** 若总体 X 属连续型, 其密度函数 $f\{X = x\} = f(x; \theta_1, \dots, \theta_m), \theta_i \in \Theta_i$ 的形式已知, 可设

$$L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_m) = \prod_{i=1}^n f(x_i; \theta_1, \dots, \theta_m).$$

Step 2

取 $\hat{\theta}_1, \dots, \hat{\theta}_m$ 使

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_m) = \max_{\theta_i \in \Theta_i} L(x_1, x_2, \dots, x_n; \theta_1, \dots, \theta_m).$$

这样得到的 $\hat{\theta}_i$ 与样本值 x_1, x_2, \dots, x_n 有关, 常记为 $\hat{\theta}_i(x_1, x_2, \dots, x_n)$, 称为参数 θ_i 的**最大似然估计值**, 相应的统计量 $\hat{\theta}_i(X_1, X_2, \dots, X_n)$ 称为参数 θ_i 的**最大似然估计量**.

Tips

连续型时, **Step 2** 通常是一个极值问题, 可以转化为求解以下方程

$$\frac{d}{d\theta_i} L(\theta_1, \dots, \theta_m) = 0,$$

若 $L > 0$, 有时 $L(\theta_1, \dots, \theta_m)$ 的对数更容易求导, 则可转化为**对数似然方程**, 即

$$\frac{d}{d\theta_i} \ln(L(\theta_1, \dots, \theta_m)) = 0.$$

注: 并不是所有连续型都可以通过以上两条方程解出极值点, 有时还要考虑定义域端点是否为最大值点.

7.2 估计量的评选标准

7.2.1 无偏性

设 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 是参数 θ 的估计量, 若 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的**无偏估计**.

若 $\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 为 θ 的**渐进无偏估计**.

7.2.2 有效性

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 都是参数 θ 的**无偏估计量** $\forall \theta \in \Theta$, 都有 $D(\hat{\theta}_1) \leq D(\hat{\theta}_2)$, 则一般情况下可称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ **有效**.

设 $\hat{\theta}_0$ 是参数 θ 的**无偏估计量**, 若对 $\forall \theta$ 的无偏估计量 $\hat{\theta}$, 有 $D(\hat{\theta}_0) \leq D(\hat{\theta})$, 则称 $\hat{\theta}_0$ 为 θ 的**最有效无偏估计**.

7.2.3 相合性

若 $\hat{\theta} \xrightarrow{P} \theta$, 即对 $\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$, 则称 $\hat{\theta}$ 为 θ 的**(弱) 相合估计**.

若 $\lim_{n \rightarrow \infty} P\{\hat{\theta} = \theta\} = 1$, 则称 $\hat{\theta}$ 为 θ 的**强相合估计**.